



Comité Nacional Peruano de la CIER

## Curso Virtual

**Python para el Análisis de Datos y la Automatización  
en el Sector Eléctrico**

**27, 29 y 31 de Octubre, 03, 05, 07, 10 y 12 de Noviembre 2025.**

**MARVIN COTO – FACILITADOR**

**E-mail: [mcotoj@gmail.com](mailto:mcotoj@gmail.com)**



## **SESIÓN 5**

### **Parte 1**

En la sesión anterior...

Numpy: Manejo de arreglos y eficiencia en cálculos.



data

1	2
3	4
5	6

`.max()` = 6

data

1	2
3	4
5	6

`.min()` = 1

data

1	2
3	4
5	6

`.sum()` = 21

**En la sesión anterior...**

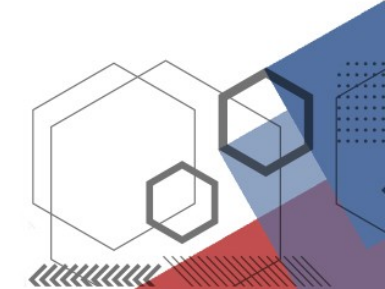
**Numpy: Repasemos lo aprendido.**

[https://docs.google.com/forms/d/e/  
1FAIpQLSeU2UkkSaj6x8DBTOar61FCQqG9Oid\\_2p8Y1KXq6Fg1LGwbZA/  
viewform?usp=header](https://docs.google.com/forms/d/e/1FAIpQLSeU2UkkSaj6x8DBTOar61FCQqG9Oid_2p8Y1KXq6Fg1LGwbZA/viewform?usp=header)

# Introducción a Pandas - DataFrames y Series

Esta sección introduce al manejo de datos usando **Pandas**, una biblioteca esencial para el sector eléctrico.

Veremos cómo representar lecturas, manipular datos y extraer estadísticas clave para toma de decisiones técnicas.



# Introducción a Pandas - DataFrames y Series

## Objetivos

- Comprender la estructura de **Series** y **DataFrames**.
- Realizar **selección, filtrado y operaciones estadísticas**.
- Aplicar Pandas a problemas reales en ingeniería eléctrica.
- Usar este módulo como **material de consulta** durante tus proyectos.


# Fundamentos de Pandas



## ¿Qué es Pandas?

Pandas es una biblioteca de Python para el análisis y manipulación de datos estructurados (filas y columnas). Útil para tareas como:

- Analizar mediciones de potencia en transformadores
- Registrar voltajes y corrientes en diferentes fases
- Procesar datos de consumo en instalaciones.





# Fundamentos de Pandas

Instalación (si no está instalada):  
`pip install pandas`

Recordatorio: pip es el manejador de paquetes (extensiones) de Python. Se usa en la línea de comando.





# Fundamentos de Pandas

## Estructuras Básicas


Una **Serie** en Pandas es un arreglo unidimensional con etiquetas (índices). Sirve para representar una sola variable a lo largo del tiempo, como la temperatura o el voltaje.

```
import pandas as pd

mediciones_voltaje = pd.Series([220.5, 221.3, 219.8, 220.2],
                               name='Voltaje (V)',
                               index=['08:00', '09:00', '10:00',
                                      '11:00'])

print(mediciones_voltaje)
```

```
08:00 220.5
09:00 221.3
10:00 219.8
11:00 220.2
Name: Voltaje (V), dtype: float64
```



# Fundamentos de Pandas

## DataFrame

Un **DataFrame** es una tabla bidimensional donde cada columna puede tener un tipo distinto de datos (números, cadenas, fechas, etc.). Representa un conjunto de mediciones eléctricas simultáneas.

```
datos_electricos = {  
    'Hora': ['08:00', '09:00', '10:00', '11:00'],  
    'Voltaje (V)': [220.5, 221.3, 219.8, 220.2],  
    'Corriente (A)': [10.2, 9.8, 10.5, 11.1],  
    'Potencia (W)': [2249.1, 2168.74, 2307.9, 2444.22]  
}
```

Esta es una de las  
formas de definir un  
dataframe

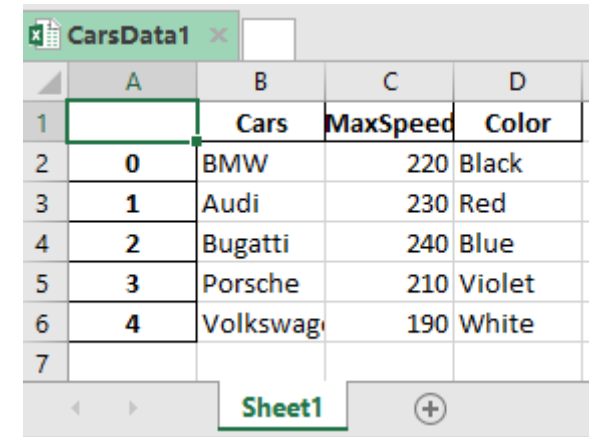
```
df_mediciones = pd.DataFrame(datos_electricos)  
print(df_mediciones)
```

# Fundamentos de Pandas

## DataFrame: Analogía

```
datos_electricos = {  
    'Hora': ['08:00', '09:00', '10:00',  
    '11:00'],  
    'Voltaje (V)': [220.5, 221.3, 219.8,  
220.2],  
    'Corriente (A)': [10.2, 9.8, 10.5, 11.1],  
    'Potencia (W)': [2249.1, 2168.74, 2307.9,  
2444.22]  
}
```

```
df_mediciones = pd.DataFrame(datos_electricos)  
print(df_mediciones)
```



	A	B	C	D
1		Cars	MaxSpeed	Color
2	0	BMW	220	Black
3	1	Audi	230	Red
4	2	Bugatti	240	Blue
5	3	Porsche	210	Violet
6	4	Volkswag	190	White
7				

# Selección y Filtrado de Datos

## Acceso a Datos con `.loc[]` y `.iloc[]`

En Pandas, existen dos formas fundamentales de seleccionar datos:

Método	Tipo de acceso	¿Usa nombres?	¿Incluye el final del rango?
<code>.loc[]</code>	Acceso por <b>etiquetas</b>	Sí	Sí
<code>.iloc[]</code>	Acceso por <b>posiciones</b>	No	No

## Selección y Filtrado de Datos

**.loc[]: Por etiquetas (nombres de filas y columnas)**

Usa etiquetas o nombres del índice o columnas para seleccionar datos. Es más legible.

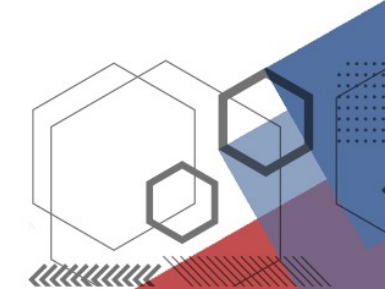
## Selección y Filtrado de Datos

### **.loc[]: Por etiquetas (nombres de filas y columnas)**

Usa etiquetas o nombres del índice o columnas para seleccionar datos. Es más legible.

### **.iloc[]: Por posición (como en listas)**

Usa números enteros para acceder a posiciones de filas y columnas. Es útil cuando no sabes los nombres.



# Selección y Filtrado de Datos

## Comparación visual

Lo que quieres hacer	<code>.loc[]</code>	<code>.iloc[]</code>
Fila por nombre	<code>df.loc['09:00']</code>	—
Fila por posición	—	<code>df.iloc[1]</code>
Rango de filas	<code>df.loc['09:00':'10:00']</code>	<code>df.iloc[1:3]</code>
Columna por nombre	<code>df.loc[:, 'Voltaje (V)']</code>	<code>df.iloc[:, 0]</code>
Varias columnas	<code>df.loc[:, ['Corriente (A)', 'Potencia (W)']]</code>	<code>df.iloc[:, 1:3]</code>
Fila y columna específica	<code>df.loc['09:00', 'Voltaje (V)']</code>	<code>df.iloc[1, 0]</code>



# Ejemplos y ejercicios



[colab.research.google.com](https://colab.research.google.com)

PECIER\_dia5\_parte1



## **SESIÓN 5**

### **Parte 2**

## Selección y Filtrado de Datos

### Filtrado de Datos

**Filtrar** significa seleccionar filas que cumplen una condición. Es clave para:

- Identificar sobrecargas
- Detectar caídas de voltaje
- Evaluar horas pico

# Selección y Filtrado de Datos

## Filtro simple

```
df_mediciones[df_mediciones['Voltaje (V)'] > 220]
```

# Selección y Filtrado de Datos

## Filtro compuesto

Para combinar condiciones se usan los operadores:

- $\&$  (AND)
- $|$  (OR)
- $\sim$  (NOT)

# Selección y Filtrado de Datos

```
condicion = (df_mediciones['Voltaje (V)'] > 219) & (df_mediciones['Corriente (A)']  
< 11)  
df_mediciones[condicion]
```

# Operaciones Estadísticas

## Estadísticas Básicas

Pandas incluye métodos para obtener estadísticas rápidas:

```
df_mediciones.describe()
```





## Operaciones Estadísticas

### Incluye:

- count: cantidad de datos
- mean: promedio
- std: desviación estándar
- min, max: valor mínimo y máximo
- 25%, 50%, 75%: percentiles

# Operaciones Estadísticas

## Otras Operaciones Útiles

Método	Descripción
<code>.mean()</code>	Promedio
<code>.max()</code>	Máximo
<code>.min()</code>	Mínimo
<code>.std()</code>	Desviación estándar
<code>.sum()</code>	Suma total
<code>.median()</code>	Mediana
<code>.value_counts()</code>	Frecuencias (para categóricos)
<code>.corr()</code>	Correlación entre columnas numéricas

# Operaciones Estadísticas

```
print(f"Voltaje promedio: {df_mediciones['Voltaje  
(V)'].mean():.2f} V") print(f"Potencia máxima:  
{df_mediciones['Potencia (W)'].max()} W")
```

# Ejemplos y ejercicios



[colab.research.google.com](https://colab.research.google.com)

PECIER\_dia5\_parte2



## **SESIÓN 5**

### **Parte 3**

# Análisis Temporal y Series de Tiempo

## Carga de Datos Reales

```
tensiones = pd.read_csv('tensiones.csv',  
                        parse_dates=['fecha'],  
                        index_col='fecha')  
print(consumo.head())
```

# Análisis Temporal y Series de Tiempo

## Agrupamiento por Intervalos (resample)

Con datos por hora o minuto, puedes agrupar por día ('D'), semana ('W') o mes ('M').

```
tension_diaria =  
tensiones['tension1'].resample('D').mean()
```



# Análisis Temporal y Series de Tiempo

## Visualización Rápida

Con datos por hora o minuto, puedes agrupar por día ('D'), semana ('W') o mes ('M').


```
import matplotlib.pyplot as plt

consumo_diario.plot(title='Consumo Promedio Diario')
plt.ylabel('Potencia (W)')
plt.grid()
plt.show()
```

# Análisis Temporal y Series de Tiempo

## Visualización Rápida

Con datos por hora o minuto, puedes agrupar por día ('D'), semana ('W') o mes ('M').



## Detección de Anomalías

Identificar valores anómalos permite detectar problemas como picos, caídas de voltaje o fallas de sensores.

```
media = consumo['Voltaje (V)'].mean() std = consumo['Voltaje (V)'].std()

anomalias = consumo[(consumo['Voltaje (V)'] < media - 3std) | (consumo['Voltaje (V)'] > media
+ 3std)]

print(f"Anomalías detectadas: {len(anomalias)}")
```

# Ejemplos y ejercicios



[colab.research.google.com](https://colab.research.google.com)

PECIER\_dia5\_parte3



## **SESIÓN 5**

### **Parte 4**

## **Filtrado, Agrupación y Agregación con Pandas y NumPy**

Esta sección tiene como objetivo cubrir los temas de manipulación y transformación de datos eléctricos con Pandas, aplicación de filtros condicionales simples y complejos y manipulación de dataframes.



# **Filtrado, Agrupación y Agregación con Pandas y NumPy**

## **Preparación del Entorno**

### **Introducción**

En el sector eléctrico es común analizar grandes volúmenes de datos horarios: voltajes, corrientes, potencias, distorsión armónica, etc. Vamos a simular datos de una instalación eléctrica trifásica con mediciones horarias durante 2 días.





# Filtrado, Agrupación y Agregación con Pandas y NumPy

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

np.random.seed(0) # reproducibilidad

n = 48 # 2 días, datos cada hora
fechas = pd.date_range('2023-01-01', periods=n, freq='H')

data = {
    'Timestamp': fechas,
    'Voltaje (V)': np.random.normal(220, 4, n),
    'Corriente (A)': np.random.normal(10, 1.5, n),
    'Fase': np.random.choice(['R', 'S', 'T'], n),
    'Consumo (kWh)': np.random.uniform(1.0, 5.0, n)
}

df = pd.DataFrame(data).set_index('Timestamp')
df.head()
```



# Manipulación de Columnas

## Introducción

Muchas veces necesitamos derivar nueva información a partir de las variables originales. Aquí aprenderemos a:


- Calcular columnas nuevas con fórmulas físicas.
- Calcular promedios móviles y desviaciones estándar.
- Clasificar datos numéricos en niveles.
- Normalizar datos para análisis comparativos.

# Manipulación de Columnas

## Potencia Aparente Estimada

**Concepto:** La potencia aparente en sistemas eléctricos se estima multiplicando voltaje por corriente.

```
df['Potencia (VA)'] = df['Voltaje (V)'] * df['Corriente (A)']
```



# Manipulación de Columnas

## Media Móvil

**Concepto:** Una media móvil suaviza las fluctuaciones y ayuda a ver tendencias.

```
df['Voltaje_prom_6'] = df['Voltaje  
(V)'].rolling(window=6).mean()
```

# Manipulación de Columnas

## Desviación Estándar Móvil

**Concepto:** Mide la variabilidad local de la señal. Aunque vamos a eliminarla luego, antes es buena práctica guardar el DataFrame:

```
df_backup = df.copy() # recomendación antes de eliminar  
columnas  
df['Voltaje_std_6'] = df['Voltaje  
(V)'].rolling(window=6).std()  
df.drop(columns='Voltaje_std_6', inplace=True)
```

# Manipulación de Columnas

## Normalización (Z-Score)

**Concepto:** Transforma la serie de tiempo en una escala centrada en cero, útil para comparación entre variables.

```
df['Voltaje_norm'] = (df['Voltaje (V)'] - df['Voltaje (V)'].mean()) / df['Voltaje (V)'].std()
```

# Manipulación de Columnas

## Clasificación Categórica de Voltaje

**Concepto:** Clasificamos los valores en categorías según su distancia a la media.

```
media = df['Voltaje (V)'].mean()  
std = df['Voltaje (V)'].std()
```

```
def clasificar_voltaje(v):  
    if v < media - std:  
        return 'Bajo'  
    elif v > media + std:  
        return 'Alto'  
    else:  
        return 'Medio'
```

```
df['Nivel Voltaje'] = df['Voltaje (V)'].apply(clasificar_voltaje)
```



# Manipulación de Columnas

## Clasificación con NumPy: `np.where()`

¿Qué es `np.where()`? Es una función de NumPy que permite crear columnas condicionales de forma rápida.

**Ejemplo:** Indicador de voltaje seguro (seguro si es menor a 230 V):

```
df['Voltaje Seguro'] = np.where(df['Voltaje (V)'] < 230, 'Sí',  
'No')
```

Esto es equivalente a:

```
# Sin np.where (más largo)  
df['Voltaje Seguro'] = df['Voltaje (V)'].apply(lambda v: 'Sí' if v < 230  
else 'No')
```

# Fusión de DataFrames

## Introducción

Muchas veces tenemos datos complementarios en distintos DataFrames. La unión de DataFrames permite integrarlos.

# Fusión de DataFrames

## Unión por Índice (.join())

```
thd = pd.DataFrame({  
    'Timestamp': fechas,  
    'THD': np.random.uniform(3, 7, n)  
}).set_index('Timestamp')  
  
df = df.join(thd)
```

## Fusión de DataFrames

### Unión por Índice (.join())

#### Para que funcione:

- Ambos DataFrames deben tener el mismo índice (DatetimeIndex).
- Si hay diferencias en los índices, el resultado puede contener NaN.

# Fusión de DataFrames

## Unión con merge ( )

```
mediciones_extra = pd.DataFrame({  
    'Timestamp': fechas,  
    'Factor_Potencia': np.random.uniform(0.85, 1.0, n)  
})  
  
df = df.reset_index().merge(mediciones_extra,  
on='Timestamp').set_index('Timestamp')
```

### Para que funcione:

- Las columnas clave deben tener el mismo nombre y tipo.
- Puede usarse how='left', how='right' o how='outer' según la necesidad.

# Fusión de DataFrames

## Extracción Parcial de información de un Dataframe

```
df_partes = df[['Voltaje (V)', 'Corriente (A)', 'Fase']]  
df_rango = df['2023-01-01 08:00':'2023-01-01 20:00']
```

# Filtrado de Datos

## Introducción

Filtrar permite trabajar solo con los datos que cumplen ciertas condiciones.

```
df[df['Corriente (A)'] > 11]
```

```
df[(df['Fase'] == 'S') & (df['Consumo (kWh)'].between(3, 4))]
```

```
df['2023-01-01']
```



# Filtrado de Datos

```
In [17]: df[df['Corriente (A)'] > 11]
```

```
Out[17]:
```

	Voltaje (V)	Corriente (A)	Fase	Consumo (kWh)	Potencia (VA)	Voltaje_prom_6	Voltaje_norm	Nivel Voltaje	Voltaje Seguro	THD	Factor_Potencia
Timestamp											
2023-01-01 22:00:00	223.457745	11.093636	S	4.712325	2478.958847	218.812586	0.601587	Medio	Sí	6.811167	0.994236
2023-01-02 00:00:00	229.079018	11.709101	R	1.127356	2682.309371	219.759039	1.844918	Alto	Sí	3.862031	0.992398
2023-01-02 09:00:00	212.076814	11.351240	T	3.920488	2407.334758	220.444444	-1.915682	Bajo	Sí	4.496680	0.902085
2023-01-02 12:00:00	224.921163	12.232378	R	1.839375	2751.320748	219.032205	0.925271	Medio	Sí	5.347137	0.921756
2023-01-02 13:00:00	224.809519	12.843834	R	1.744772	2887.416096	219.581683	0.900577	Medio	Sí	6.455422	0.924609
2023-01-02 14:00:00	218.450693	11.768169	R	4.777490	2570.764748	219.915323	-0.505888	Medio	Sí	3.470127	0.945921
2023-01-02 17:00:00	214.319928	11.581678	S	1.909659	2482.184310	219.516313	-1.419543	Bajo	Sí	5.867439	0.973318
2023-01-02 19:00:00	227.803102	11.833668	R	1.232117	2695.746184	218.057536	1.562707	Alto	Sí	5.261685	0.926698
2023-01-02 21:00:00	218.247703	11.464959	T	2.247184	2502.200867	217.885472	-0.550786	Medio	Sí	3.579391	0.864677
2023-01-02 23:00:00	223.109961	11.059860	S	2.511007	2467.564883	219.214316	0.524664	Medio	Sí	4.422451	0.995938

# Filtrado de Datos

```
In [18]: df[(df['Fase'] == 'S') & (df['Consumo (kWh)'].between(3, 4))]
```

Out[18]:

	Voltaje (V)	Corriente (A)	Fase	Consumo (kWh)	Potencia (VA)	Voltaje_prom_6	Voltaje_norm	Nivel Voltaje	Voltaje Seguro	THD	Factor_Potencia
Timestamp											
2023-01-01 05:00:00	216.090888	8.229052	S	3.789715	1778.223098	224.182747	-1.027837	Bajo	Sí	5.146317	0.932829
2023-01-01 15:00:00	221.334697	7.410576	S	3.084146	1640.217617	222.172378	0.132005	Medio	Sí	5.353268	0.892260
2023-01-02 02:00:00	220.183034	10.603512	S	3.485914	2334.713546	221.091358	-0.122723	Medio	Sí	5.923423	0.969880
2023-01-02 22:00:00	214.988819	10.534550	S	3.785374	2264.810372	217.749310	-1.271596	Bajo	Sí	4.952225	0.979329

# Agrupación y Agregación

## Introducción

Agrupar permite calcular estadísticas por categorías (como por fase o por hora).

```
df.groupby('Fase')[['Voltaje (V)', 'Corriente (A)']].mean()
```

```
df.groupby('Fase').agg({  
    'Voltaje (V)': ['mean', 'max'],  
    'Corriente (A)': ['std'],  
    'Consumo (kWh)': ['sum']  
})
```

# Agrupación y Agregación

## Introducción

Agrupar permite calcular estadísticas por categorías (como por fase o por hora).

```
In [23]: df.groupby('Fase').agg({  
        'Voltaje (V)': ['mean', 'max'],  
        'Corriente (A)': ['std'],  
        'Consumo (kWh)': ['sum']  
    })
```

```
Out[23]:
```

	Voltaje (V)		Corriente (A)	Consumo (kWh)
	mean	max	std	sum
Fase				
R	221.772391	229.079018	1.528422	44.848753
S	220.379685	228.963573	1.205664	50.936867
T	220.016130	226.131117	1.190419	44.261812

## Agrupación y Agregación

Por hora:

```
df['Hora'] = df.index.hour  
df.groupby('Hora')['Consumo  
(kWh)'].mean()
```

# Ejemplos y ejercicios



[colab.research.google.com](https://colab.research.google.com)

PECIER\_dia5\_parte4



## **SESIÓN 5**

### **Parte 5**



# Visualización de Datos con Matplotlib y Seaborn para aplicaciones del Sector Eléctrico

## Objetivos

- Dominar los fundamentos de visualización con Matplotlib
- Comprender las ventajas de Seaborn en el análisis estadístico
- Crear visualizaciones profesionales para análisis eléctricos

## Introducción

### ¿Por qué es importante visualizar datos?

Los sistemas eléctricos generan grandes volúmenes de datos, como:

- Mediciones de voltaje, corriente, frecuencia y potencia
- Calidad de energía y distorsiones armónicas
- Cargas por fases, balanceo de redes, entre otros

## Introducción

Una buena visualización permite:


- Identificar picos, caídas o patrones repetitivos
- Detectar fallos o condiciones anómalas
- Tomar decisiones rápidas y comunicar hallazgos

# Bibliotecas Matplotlib y Seaborn

## ¿Qué es Matplotlib?

Matplotlib es la biblioteca más antigua y flexible de gráficos en Python. Permite crear gráficos altamente personalizados como líneas, barras, histogramas, dispersión, etc.

- Módulo principal: pyplot
- Pensado como una herramienta estilo MATLAB
- Alta personalización manual



# Bibliotecas Matplotlib y Seaborn

## ¿Qué es Seaborn?

- Seaborn está construida sobre Matplotlib, y facilita la creación de gráficos estadísticos. Se destaca por:
- Gráficos estéticos por defecto
- Integración directa con pandas
- Funcionalidades estadísticas como regresiones, boxplots y mapas de calor

# Bibliotecas Matplotlib y Seaborn

## ¿Qué es Seaborn?

Característica	Matplotlib	Seaborn
Control detallado	Sí	Parcial
Fácil de usar	Parcial	Sí
Gráficos estadísticos	No	Sí
Integración con Pandas	Sí	Sí

**Recomendación:** Usar Matplotlib para control completos. Usar Seaborn para análisis rápidos y exploración.



# Configuración Inicial

## Cargar bibliotecas y crear dataset de ejemplo

```
import matplotlib.pyplot as plt
import seaborn as sns
import pandas as pd
import numpy as np

plt.style.use('seaborn-v0_8') # Estilo
predeterminado moderno
sns.set_palette("husl")      # Paleta de
colores para Seaborn
%matplotlib inline
```



# Configuración Inicial

## Crear datos de simulación

```
np.random.seed(42)


horas = pd.date_range('2023-06-01', periods=24, freq='H')
datos = {
    'Hora': horas,
    'Voltaje': np.random.normal(220, 5, 24),
    'Corriente': np.random.gamma(5, 0.5, 24),
    'Potencia': np.random.uniform(1000, 5000, 24),
    'Fase': np.random.choice(['R', 'S', 'T'], 24)
}
df = pd.DataFrame(datos).set_index('Hora')
```

# Visualización con Matplotlib

## Gráficos de Líneas

¿Cuándo son útiles estos gráficos?

- Series temporales como voltaje diario, temperatura, potencia
- Comparación con valores nominales



# Visualización con Matplotlib


## Ejemplo: Voltaje a lo largo del día

```
plt.figure(figsize=(12, 5))
plt.plot(df.index, df['Voltaje'],
         marker='o',                # Estilo del punto (otros: 's' cuadrado, '^' tria
         linestyle='--',            # '--' = línea punteada. También: '-' sólida, '-'
         color='b',                 # 'b' = azul. Otros: 'r' rojo, 'g' verde, 'k' neg
         label='Voltaje (V)')       # Etiqueta de leyenda

plt.axhline(220, color='r', linestyle=':', label='Valor nominal')
plt.title('Variación de Voltaje en 24 Horas')
plt.xlabel('Hora del día')
plt.ylabel('Voltaje (V)')
plt.legend()
plt.grid(True)
plt.show()
```

# Visualización con Matplotlib

## Ejemplo: Voltaje a lo largo del día



# Visualización con Matplotlib

## Explicación de cada línea

Elemento	Significado
<code>plt.plot()</code>	Crea gráfico de líneas
<code>marker='o'</code>	Marca cada punto con círculo
<code>linestyle='--'</code>	Línea punteada
<code>color='b'</code>	Color azul
<code>axhline()</code>	Línea horizontal (valor de referencia)

# Visualización con Matplotlib

## Histogramas

### ¿Cuándo son útiles los histogramas?

- Para visualizar distribución de una variable (frecuencia)
- Útil para corriente, THD, factor de potencia

# Visualización con Matplotlib

## Histogramas

### Ejemplo: Distribución de corriente

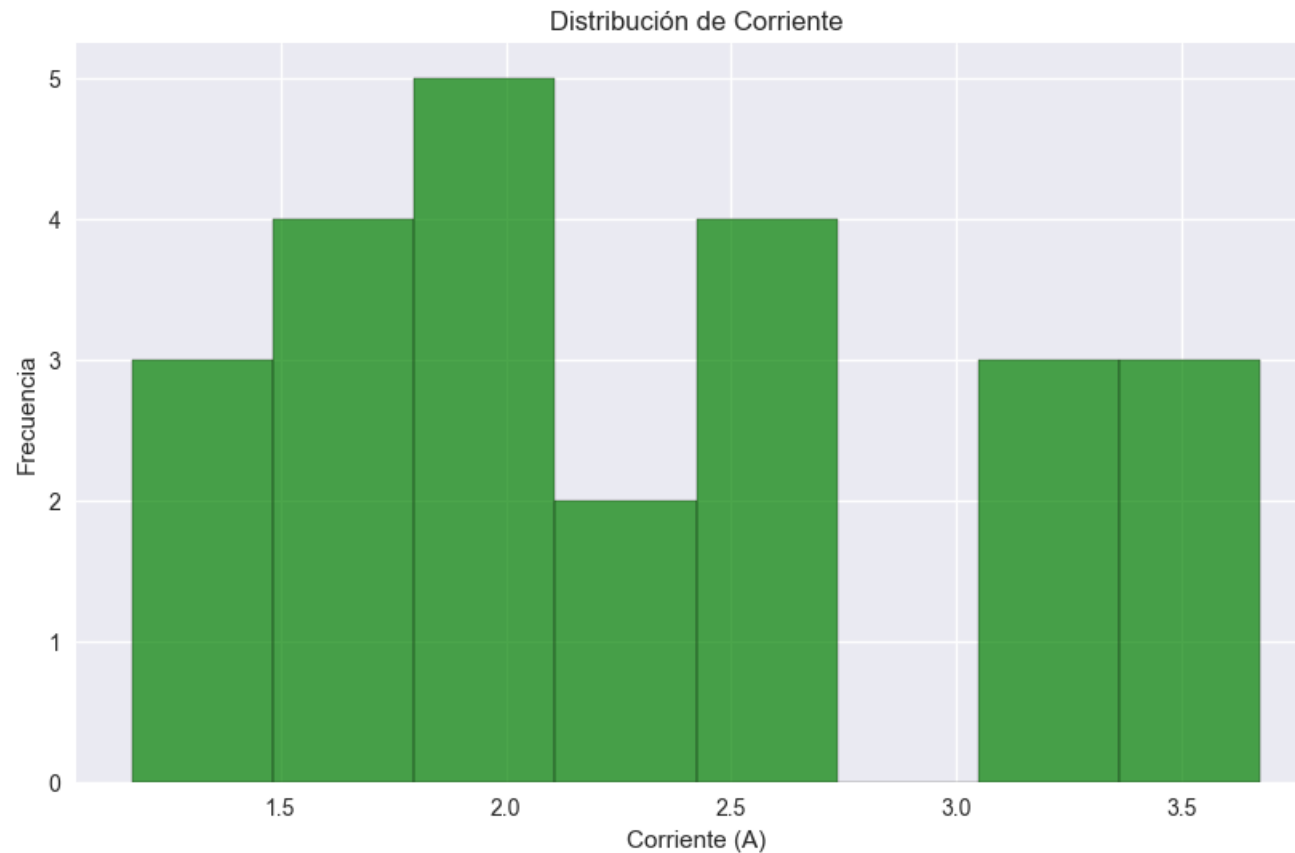
```
plt.figure(figsize=(10, 6))
plt.hist(df['Corriente'],
        bins=8,          # Número de bloques
        color='green',
        alpha=0.7,        # Transparencia (0 = invisible, 1 = opaco)
        edgecolor='black') # Borde de las barras
plt.title('Distribución de Corriente')
plt.xlabel('Corriente (A)')
plt.ylabel('Frecuencia')
plt.show()
```



# Visualización con Matplotlib

## Histogramas

Ejemplo: Distribución de corriente



# Visualización con Matplotlib

## Gráficos de Dispersión + Regresión

### ¿Cuándo son útiles?

- Para analizar correlación entre dos variables
- Ej: corriente vs potencia, THD vs temperatura

# Visualización con Matplotlib

## Gráficos de Dispersión + Regresión

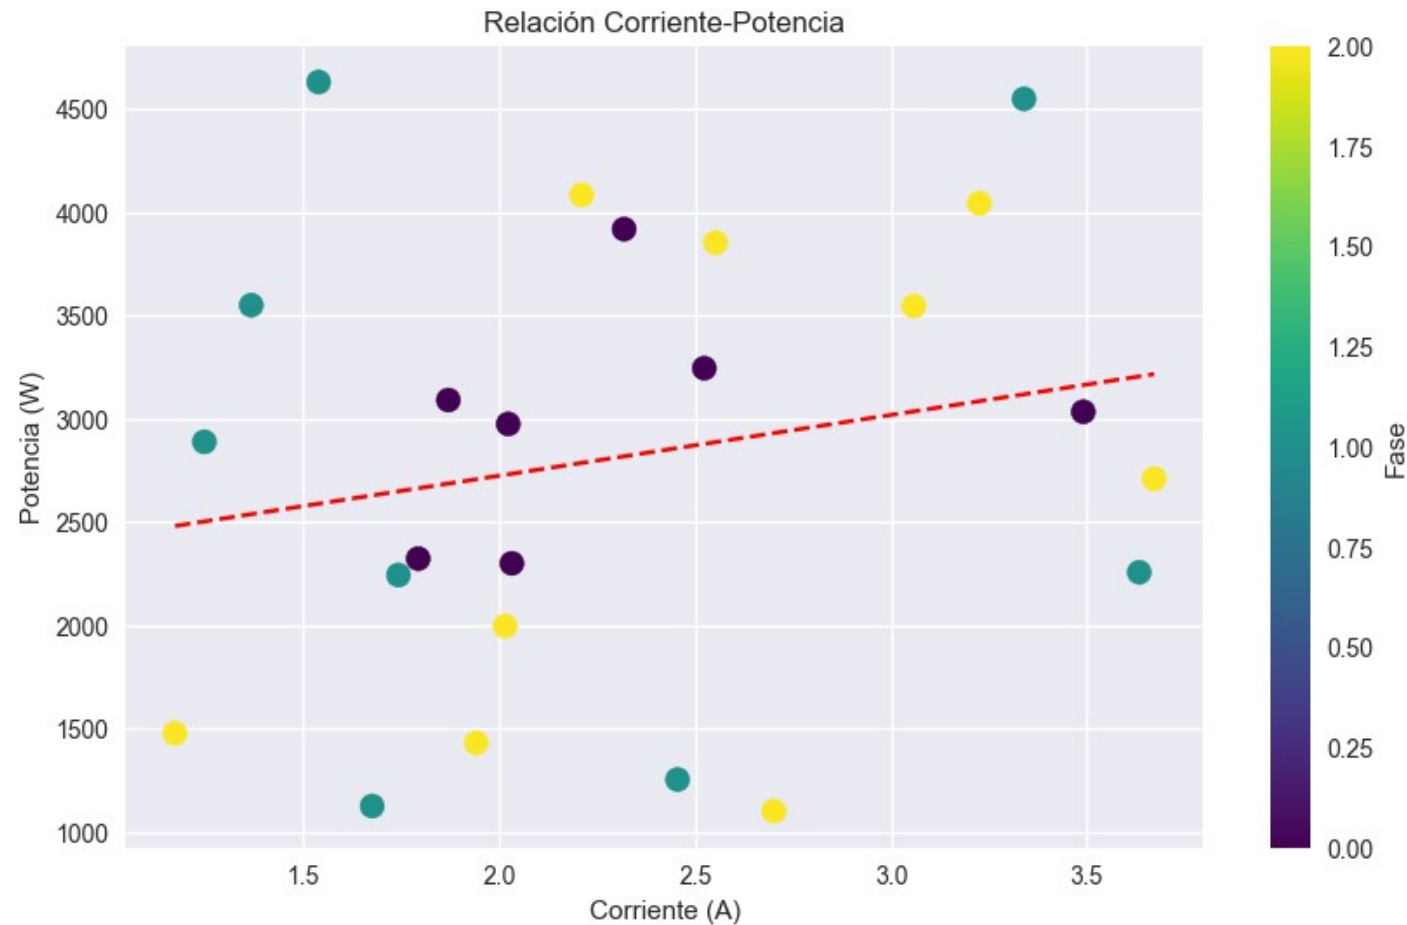
Ejemplo:

```
plt.figure(figsize=(10, 6))
plt.scatter(df['Corriente'], df['Potencia'],
            c=pd.factorize(df['Fase'])[0], # Codifica R/S/T como
0/1/2
            cmap='viridis',                # Mapa de color
            s=100)                         # Tamaño de puntos
plt.colorbar(label='Fase')
plt.plot(np.unique(df['Corriente']),
         np.poly1d(np.polyfit(df['Corriente'], df['Potencia'], 1))
         (np.unique(df['Corriente'])),
         'r--') # Línea de regresión (roja punteada)
plt.title('Relación Corriente-Potencia')
plt.xlabel('Corriente (A)')
plt.ylabel('Potencia (W)')
plt.show()
```

# Visualización con Matplotlib

## Gráficos de Dispersión + Regresión

Ejemplo:



# Visualización con Seaborn

## Boxplots + Swarmplots

### ¿Cuándo usarlo?

- Comparar valores por grupo (fases, días, zonas)
- Ver valores extremos (outliers) y mediana

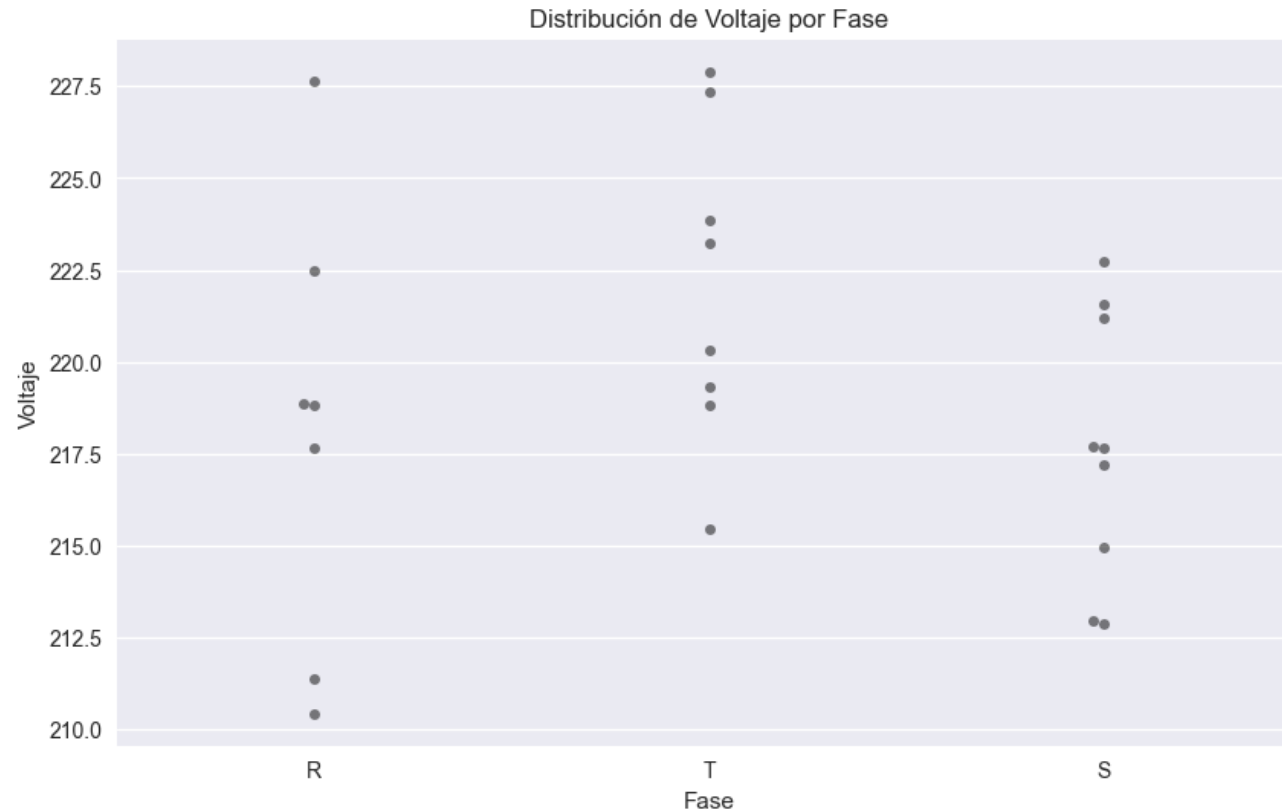
# Visualización con Seaborn

## Ejemplo:

```
plt.figure(figsize=(10, 6))
#sns.boxplot(x='Fase', y='Voltaje', data=df.reset_index(),
#           width=0.3, notch=True) # notch=True muestra intervalo de
#confianza
sns.swarmplot(x='Fase', y='Voltaje', data=df.reset_index(),
              color='black', alpha=0.5) # Puntos individuales
plt.title('Distribución de Voltaje por Fase')
plt.show()
```

# Visualización con Seaborn

**Ejemplo:**



Recomendación: Ver <https://www.geeksforgeeks.org/python/swarmplot-using-seaborn-in-python/>



# Visualización con Seaborn

## Mapa de calor de correlaciones

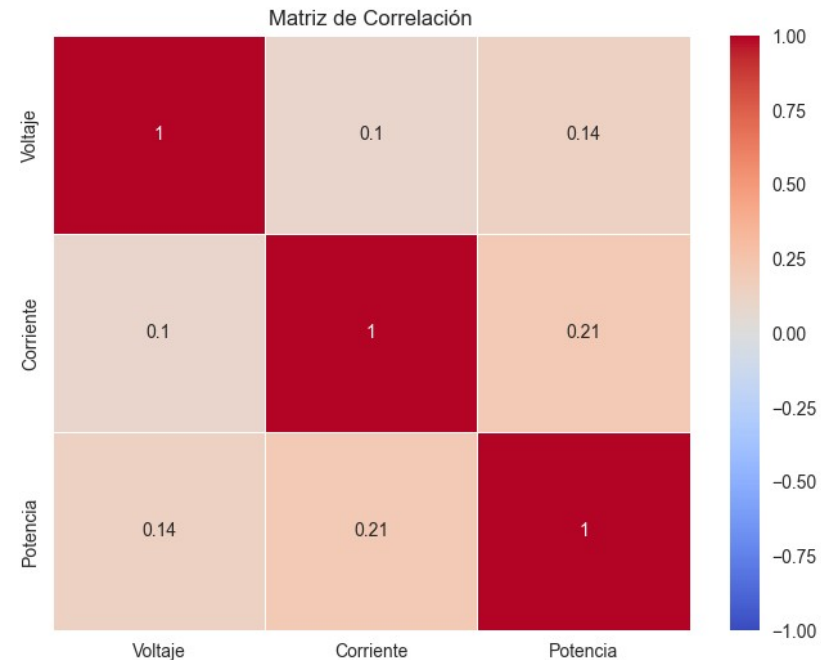
### ¿Cuándo usar?

- Visualizar qué variables están correlacionadas
- Identificar relaciones lineales

# Visualización con Seaborn

## Ejemplo:

```
corr = df[['Voltaje', 'Corriente', 'Potencia']].corr()  
plt.figure(figsize=(8, 6))  
sns.heatmap(corr, annot=True, cmap='coolwarm', vmin=-1, vmax=1, linewidths=0.5)  
plt.title('Matriz de Correlación')  
plt.show()
```



# Visualización Temporal Avanzada

## Ejemplo con datos de una semana

Este gráfico muestra cómo varía el voltaje cada día, comparando por hora.

```
semana = pd.date_range('2023-06-01', periods=7*24, freq='H')
df_semana = pd.DataFrame({
    'Timestamp': semana,
    'Voltaje': np.random.normal(220, 3, len(semana)) +
5*np.sin(2*np.pi*semana.hour/24),
    'Consumo': np.random.gamma(5, 100, len(semana)),
    'Dia': semana.day_name(),
    'Hora': semana.hour
}).set_index('Timestamp')
```

# Visualización Temporal Avanzada

## Ejemplo con datos de una semana


Este gráfico muestra cómo varía el voltaje cada día, comparando por hora.

```
plt.figure(figsize=(14, 7))
sns.lineplot(data=df_semana.reset_index(),
             x='Hora',
             y='Voltaje',
             hue='Dia',
             style='Dia',
             markers=True,
             dashes=False,
             palette='tab10')
plt.title('Variación Diaria de Voltaje durante una Semana')
plt.xticks(range(0, 24))
plt.grid(True)
plt.show()
```

# Visualización Temporal Avanzada

## Ejemplo con datos de una semana

Este gráfico muestra cómo varía el voltaje cada día, comparando por hora.



# Dashboard de Monitoreo Eléctrico

## ¿Qué es un dashboard?

Un **dashboard** (tablero de control) es una visualización compuesta que presenta múltiples gráficos para monitorear variables clave. En el contexto eléctrico, permite observar:

- Tendencias generales
- Anomalías en tiempo real
- Distribuciones y correlaciones entre variables



# Dashboard de Monitoreo Eléctrico

## Ejemplo de un Dashboard

Vamos a construir un dashboard que incluya:


- Serie temporal
- Histograma
- Boxplot
- Mapa de calor
- Dispersión con colores por día



# Dashboard de Monitoreo Eléctrico

## Explicación

- Se usa gridspec para organizar el layout (3 filas × 2 columnas)
- Cada gráfico ocupa su propia celda o combinación de celdas
- Las visualizaciones permiten inspección cruzada de variable



# Análisis de Anomalías

## ¿Qué es una anomalía?

En sistemas eléctricos, una anomalía puede ser:

- Voltaje fuera de rango
- Consumo anormalmente alto o bajo
- Eventos que exceden límites estadísticos

# Análisis de Anomalías

## Detección con 2 desviaciones estándar

```
def detectar_anomalias(df):  
    mean_v = df['Voltaje'].mean()  
    std_v = df['Voltaje'].std()  
  
    df['Anomalia'] = (df['Voltaje'] < mean_v - 2 * std_v) | \  
                    (df['Voltaje'] > mean_v + 2 * std_v)  
  
    plt.figure(figsize=(14, 6))  
    sns.scatterplot(data=df.reset_index(),  
                    x='Timestamp',  
                    y='Voltaje',  
                    hue='Anomalia',  
                    palette={True: 'red', False: 'blue'},  
                    style='Anomalia',  
                    s=100)
```

# Análisis de Anomalías

## Detección con 2 desviaciones estándar

```
plt.axhline(mean_v, color='green', linestyle='--', label='Media')
plt.axhline(mean_v + 2 * std_v, color='orange', linestyle=':',
label='Límites')
plt.axhline(mean_v - 2 * std_v, color='orange', linestyle=':')
plt.title('Detección de Anomalías en Voltaje')
plt.legend()
plt.show()

return df[df['Anomalia']]

anomalias = detectar_anomalias(df_semana)
print(f"Anomalías detectadas: {len(anomalias)}")
```

# Ejemplos y ejercicios



[colab.research.google.com](https://colab.research.google.com)

PECIER\_dia5\_parte5



Comité Nacional Peruano de la CIER

**E-mail: [pecier@cier.org](mailto:pecier@cier.org)**